

Análisis de Varianza (ANOVA de 1 Factor) y Pruebas Post-Hoc (Tukey HSD)

Estudiantes: Selena Castillo, Joaquin Moscol, Jefferson Sarango, Irvin Armijos, Matias Romero

Link al Google Colab:

https://colab.research.google.com/drive/1dEeEgRbot1m2N3o18_CHwWt2G1HWi3bc?usp=sharing

4. Preguntas de Control: Validación de Supuestos y Alternativas

El ANOVA de un factor asume, entre otras cosas, homocedasticidad: que la varianza de la variable de respuesta es aproximadamente igual en todos los grupos comparados. Esta sección evalúa dicho supuesto y explora una alternativa robusta cuando no se cumple.

4.1 Test de Levene (homogeneidad de varianzas)

```
4.1 Test de Levene (homogeneidad de varianzas)

levene_stat, levene_p = stats.levene(grupo_casa, grupo_depto, grupo_cuarto)

print("=== Test de Levene (homocedasticidad) ===")
print(f"Estadístico : {levene_stat:.4f}")
print(f"Valor-p      : {levene_p:.4e}")

if levene_p < 0.05:
    print("\nConclusión: p-valor < 0.05 → se RECHAZA H0 de igualdad de varianzas.")
    print("El supuesto de homocedasticidad NO se cumple (varianzas heterogéneas).")
else:
    print("\nConclusión: p-valor ≥ 0.05 → no se rechaza H0. Varianzas homogéneas.")

=== Test de Levene (homocedasticidad) ===
Estadístico : 112.4171
Valor-p      : 6.3410e-49

Conclusión: p-valor < 0.05 → se RECHAZA H0 de igualdad de varianzas.
El supuesto de homocedasticidad NO se cumple (varianzas heterogéneas).
```

Interpretación del test de Levene: el estadístico obtenido (≈ 112.42) junto con un valor-p $\approx 6.34 \times 10^{-49}$ (muy inferior a $\alpha = 0.05$) lleva a rechazar la hipótesis nula de igualdad de varianzas. Esto confirma que el supuesto de homocedasticidad se viola entre los tres grupos de tipo de vivienda: la desviación estándar del arriendo en Casa/Villa (≈ 118.8 USD) es sustancialmente mayor que la de Departamento (≈ 73.3 USD) y la de Cuarto en casa de inquilinato (≈ 44.9 USD).

¿Por qué ocurre esto en datos económicos de arriendo? Este patrón es habitual —y esperado— en variables monetarias de tipo socioeconómico por varias razones:

1. **Naturaleza asimétrica y de cola pesada (right-skewed) del ingreso/gasto:** las variables monetarias rara vez se distribuyen de forma simétrica; suelen presentar una cola larga hacia la derecha, ya que existen viviendas de lujo o zonas de alta plusvalía con arriendos

muy superiores a la mediana, mientras que el límite inferior (arriendo mínimo) está acotado cerca de cero.

2. **Heterogeneidad estructural del segmento "Casa/Villa":** esta categoría agrupa un universo mucho más amplio y diverso de viviendas (desde casas modestas en zonas rurales hasta residencias de alto valor en zonas urbanas exclusivas), lo que naturalmente incrementa su varianza interna respecto a categorías más homogéneas como "Cuarto en casa de inquilinato", que corresponde a un segmento de vivienda económica con rangos de precio mucho más acotados.
3. **Relación entre media y varianza (efecto multiplicativo):** en variables económicas es común que la varianza crezca proporcionalmente al nivel de la media (a mayor arriendo promedio, mayor también su dispersión absoluta en dólares), lo cual es consistente con lo observado: el grupo con mayor media (Casa/Villa) es también el que exhibe mayor desviación estándar.

Solución robusta: Kruskal-Wallis

Dado que el supuesto de homocedasticidad no se cumple, la validez estricta del ANOVA paramétrico queda comprometida (aunque, gracias al elevado tamaño muestral, la prueba F suele ser razonablemente robusta ante desviaciones moderadas de este supuesto). Como alternativa metodológicamente más apropiada, se aplica la prueba no paramétrica de Kruskal-Wallis, la cual no asume normalidad ni homogeneidad de varianzas, ya que opera sobre los rangos (rankings) de las observaciones en lugar de sus valores absolutos.

4.3 Prueba de Kruskal-Wallis

4.3 Prueba de Kruskal-Wallis

```
kw_stat, kw_p = stats.kruskal(grupo_casa, grupo_depto, grupo_cuarto)

print("=== Prueba de Kruskal-Wallis ===")
print(f"Estadístico H : {kw_stat:.4f}")
print(f"Valor-p      : {kw_p:.4e}")

if kw_p < 0.05:
    print("\nConclusión: p-valor < 0.05 → se RECHAZA H0.")
    print("Existe evidencia de que al menos un grupo tiene una distribución de arriendo distinta.")
else:
    print("\nConclusión: p-valor ≥ 0.05 → no se rechaza H0.")

print("\n--- Comparación de conclusiones ---")
print(f"ANOVA (paramétrico)      : F = {f_stat_real:.2f}, p = {p_value_real:.3e}")
print(f"Kruskal-Wallis (no param): H = {kw_stat:.2f}, p = {kw_p:.3e}")

'''
=== Prueba de Kruskal-Wallis ===
Estadístico H : 1334.2505
Valor-p      : 1.8671e-290

Conclusión: p-valor < 0.05 → se RECHAZA H0.
Existe evidencia de que al menos un grupo tiene una distribución de arriendo distinta.

--- Comparación de conclusiones ---
ANOVA (paramétrico)      : F = 433.93, p = 2.640e-180
Kruskal-Wallis (no param): H = 1334.25, p = 1.867e-290
```

Comparación con el ANOVA paramétrico: la prueba de Kruskal-Wallis arroja un estadístico $H \approx 1334.25$ con un valor- $p \approx 1.87 \times 10^{-290}$, igualmente muy inferior a $\alpha = 0.05$. La conclusión de ambas pruebas es coincidente: se rechaza la hipótesis nula de igualdad (de medias en el caso del ANOVA, de distribuciones/rangos medianos en el caso de Kruskal-Wallis) entre los tres tipos de vivienda. Este acuerdo entre el método paramétrico y su alternativa robusta refuerza la solidez de la conclusión sustantiva: independientemente de si se asume o no normalidad y homocedasticidad, la evidencia muestral respalda de forma consistente que el tipo de vivienda está asociado a diferencias reales en el gasto de arriendo reportado por los hogares ecuatorianos encuestados. En un reporte técnico riguroso, dado el incumplimiento confirmado de homocedasticidad, se recomendaría reportar el resultado de Kruskal-Wallis como la prueba principal de referencia, complementada por Tukey HSD (o su análogo no paramétrico, como el test de Dunn) para las comparaciones por pares.

5. Conclusiones

Conclusiones técnicas

1. La segmentación multigrupo revela una jerarquía de gasto estadísticamente robusta. El ANOVA de un factor ($F = 433.93$, $p < 0.001$) y su confirmación mediante Kruskal-Wallis ($H = 1334.25$, $p < 0.001$) demuestran, con un nivel de confianza superior al 99.9%, que el tipo de vivienda (vi01) es una variable categórica con poder explicativo real sobre el gasto mensual de arriendo (vi141) en el módulo de Vivienda y Hogar de la ENEMDU, sustentando la pertinencia de segmentar hogares por tipo de vivienda en análisis socioeconómicos posteriores.
2. Las pruebas post-hoc son indispensables para traducir un resultado ómnibus en conclusiones accionables. El ANOVA por sí solo únicamente indicó que *existía* una diferencia, mientras que Tukey HSD permitió establecer, con control formal del Family-Wise Error Rate, que las tres categorías de vivienda difieren entre sí de forma estadísticamente significativa (Casa/Villa > Departamento > Cuarto en casa de inquilinato), evitando así el inflado del error Tipo I que se hubiera producido al ejecutar tres pruebas t independientes sin corrección.
3. La verificación de supuestos es un paso metodológico no negociable, no un mero formalismo. El test de Levene reveló heterocedasticidad significativa ($p \approx 6.34 \times 10^{-49}$) entre los grupos, un hallazgo consistente con la naturaleza asimétrica y heterogénea de las variables monetarias en encuestas de hogares. Ignorar esta violación sin contrastarla habría comprometido la validez formal de las conclusiones del ANOVA paramétrico.

4. La convergencia entre métodos paramétricos y no paramétricos fortalece la validez externa del hallazgo. El hecho de que Kruskal-Wallis —una prueba que no depende de los supuestos de normalidad ni homocedasticidad— arroje la misma conclusión sustantiva que el ANOVA clásico constituye una forma de triangulación metodológica: la diferencia en el gasto de arriendo entre tipos de vivienda no es un artefacto del incumplimiento de supuestos, sino un patrón real presente en los datos de la encuesta, reforzando la confiabilidad de los resultados de aprendizaje esperados en esta práctica (dominio del ciclo completo: prueba paramétrica → validación de supuestos → alternativa robusta).