

APE12

Análisis Bivariado y Predicción: Correlación de Pearson y Modelo de Regresión Lineal Simple (OLS)

Estudiantes: Selena Castillo, Joaquin Moscol, Jefferson Sarango, Irvin Armijos, Matias Romero

Link al Google Colab:

<https://colab.research.google.com/drive/1nxJPSEH-EnbAzMzcbzw5gE3j691vpJkX?usp=sharing>

Preguntas de control

1. Análisis de Sensibilidad

La pendiente del modelo de regresión tiene sentido lógico porque existe una relación positiva entre el número de cuartos de una vivienda (X) y el valor del arriendo (Y). Esto significa que al aumentar el número de cuartos también aumenta el precio estimado del arriendo. Un incremento de un cuarto adicional genera un aumento en el valor esperado del arriendo según la pendiente estimada por el modelo. Este resultado es coherente con la realidad de la región porque las viviendas con más cuartos suelen tener un mayor valor de alquiler. Además, el modelo permitió realizar una predicción para una vivienda de 13 cuartos, lo que demuestra su utilidad para estimar el precio de viviendas que no estaban en el conjunto de datos.

2. Inferencia y Significancia: En el resumen de statsmodels, ¿qué indica el P-value (Prob>|t|) del predictor respecto a la Hipótesis Nula (H0)? ¿Qué riesgo corre su modelo si este valor supera el umbral de 0.05?

El P-value evalúa la hipótesis nula $H_0: \beta_1 = 0$, es decir, que la variable independiente no tiene efecto sobre la variable dependiente. Dado que el valor p obtenido es menor a 0.05, se rechaza la hipótesis nula, concluyendo que el predictor es estadísticamente significativo. Si el valor p fuera mayor a 0.05, el modelo correría el riesgo de no ser confiable, ya que la relación observada podría deberse al azar y no a una relación real entre las variables.

3. Bondad de Ajuste vs. Relación Lineal: ¿Cómo explica usted la diferencia conceptual entre el Coeficiente de Correlación (r) y el R^2 ? Si el R^2 es bajo (p.ej., < 0.5), ¿qué nos dice sobre la variabilidad de sus datos que el modelo lineal no está logrando capturar?

El coeficiente de correlación (r) mide la fuerza y dirección de la relación lineal entre dos variables, mientras que el coeficiente de determinación (R^2) mide la proporción de la variabilidad de la variable dependiente que es explicada por el modelo. En este caso, $R^2 = 0.922$ indica que el 92.2% de la variabilidad de Y es explicada por X . Si el R^2 fuera bajo, implicaría que el modelo no logra capturar gran parte de la variabilidad de los datos, sugiriendo la existencia de otros factores relevantes no considerados.

4. Límites de la Predicción: ¿Qué riesgos de sesgo o error se introducen al realizar extrapolaciones fuera del dominio de los datos observados? Ilustre con un caso hipotético de su proyecto.

La extrapolación introduce riesgos debido a que se realizan predicciones fuera del rango de datos observados. En este caso, se estimó un valor para X superior al máximo observado, lo cual puede no ser representativo del comportamiento real del sistema. El modelo asume que la relación lineal se mantiene constante, lo cual puede no cumplirse en valores extremos, generando posibles errores o sesgos en la predicción.

5. Validación de Supuestos (ABI): Si en su diagnóstico de residuos observa un patrón no aleatorio (por ejemplo, forma de 'U' o abanico), ¿por qué es inválido asumir que el modelo es lineal? ¿Qué alternativa sugeriría para ajustar mejor la relación entre X e Y ?

Si los residuos presentan un patrón no aleatorio, se viola el supuesto de linealidad del modelo. Esto indica que la relación entre las variables no es adecuadamente representada por una recta. En tales casos, el modelo lineal es inválido. Como alternativa, se pueden emplear modelos de regresión no lineal, como regresión polinómica o transformaciones de variables, para capturar mejor la estructura de los datos.