

APE13 (Análisis Predictivo Multivariado): Desarrollo de modelos de Regresión Lineal Múltiple y diagnóstico de colinealidad mediante el Factor de Inflación de la Varianza (VIF).

Estudiantes: Selena Castillo, Joaquin Moscol, Jefferson Sarango, Irvin Armijos, Matias Romero

Link al Google Colab:

<https://colab.research.google.com/drive/1YIEYzqOGfcVGrh-RA43g1mvoGnXCGjrL?usp=sharing>

Preguntas de control

- **Considerando la naturaleza de la causalidad, ¿cómo la lógica de 'mantener las demás variables constantes' permite aislar el efecto de un factor específico en un fenómeno complejo, y qué limitaciones filosóficas impone esto a la realidad?**

En matemáticas y estadística, la lógica de "mantener las demás variables constantes" (ceteris paribus) permite aislar el efecto de un factor específico al congelar teóricamente el entorno, funcionando como apagar todos los interruptores de una casa excepto uno para identificar con precisión qué variable produce el cambio en la respuesta.

- **Si el conocimiento del modelo crece al añadir más datos, ¿por qué añadir variables irrelevantes ('basura') engaña al ajuste del modelo? ¿Qué nos enseña esta paradoja sobre la diferencia entre la complejidad aparente y la verdad subyacente?**

Añadir variables irrelevantes o "basura" engaña al modelo de regresión porque el algoritmo, en su búsqueda matemática de reducir el error, siempre aumenta su métrica de ajuste al encontrar coincidencias aleatorias y ruido en los datos para justificar la ecuación, un fenómeno conocido como sobreajuste (overfitting) donde el modelo memoriza datos inútiles en lugar de aprender el patrón real. Esta paradoja nos enseña que una mayor complejidad aparente en una ecuación no equivale a una mayor veracidad, revelando que la verdad subyacente de los fenómenos naturales suele ser simple, elegante y generalizable, tal como lo dicta el principio de la Navaja de Ockham al postular que la explicación más sencilla y con menos suposiciones suele ser la correcta.

- **Ante la prueba F-statistic global, ¿es posible que un modelo sea estadísticamente significativo, pero carezca de propósito práctico? ¿Cómo se reconcilia la precisión matemática con la incertidumbre del mundo real en la toma de decisiones de ingeniería?**

Es completamente posible que un modelo sea estadísticamente significativo ante una prueba F-statistic global y carezca por completo de propósito práctico, ya que en datasets masivos el modelo puede detectar correlaciones microscópicas con un valor-p casi nulo pero que explican

un porcentaje ínfimo e irrelevante del problema real (por ejemplo, apenas un de la varianza). Para reconciliar esta precisión matemática con la incertidumbre del mundo real, la toma de decisiones en ingeniería no utiliza la estadística como un juez absoluto, sino que la pondera frente a criterios prácticos como el tamaño real del efecto, los costos de implementación, las tolerancias de fallo y la viabilidad técnica, preguntándose siempre si esa predicción es lo suficientemente robusta, estable y rentable para resolver un problema físico real sin romperse o encarecer innecesariamente un proyecto.

- **Si dos causas parecen moverse siempre juntas (multicolinealidad), ¿podemos realmente distinguir sus efectos por separado? ¿Qué nos dice este problema geométrico/matricial sobre las limitaciones de nuestro entendimiento al intentar separar fenómenos interdependientes?**

Cuando dos o más causas sufren de multicolinealidad y se mueven siempre juntas, resulta matemáticamente imposible distinguir sus efectos por separado, ya que el modelo entra en un cortocircuito analítico al no poder determinar cuál de las variables correlacionadas es la que verdaderamente impulsa el cambio en la variable respuesta, volviendo ilógicos e inestables a los coeficientes.

- **Ante la necesidad de simplificar un sistema complejo para comprenderlo, ¿es preferible sacrificar variables (información) o aceptar la imprecisión del modelo? ¿Qué define, bajo su criterio, a un 'buen' modelo para la ingeniería?**

Ante la necesidad de simplificar un sistema complejo, la práctica estándar y más segura en ingeniería es preferir el sacrificio de variables irrelevantes o redundantes (parsimonia) y aceptar una ínfima imprecisión teórica en lugar de construir un modelo sobrecargado que falle estrepitosamente al enfrentarse a la imprevisibilidad de nuevos datos en el mundo real. Bajo esta premisa, y recordando la máxima de George Box de que "todos los modelos están equivocados, pero algunos son útiles", un "buen" modelo de ingeniería se define como una herramienta práctica, generalizable y robusta que logra explicar la mayor cantidad posible de un problema utilizando el menor número de variables, siendo lo suficientemente intuitivo, rentable y confiable para que un ingeniero pueda tomar decisiones técnicas seguras bajo condiciones reales de incertidumbre.