

APE15 (Evaluación Avanzada de Modelos): Construcción de curvas ROC, cálculo del Área Bajo la Curva (métrica AUC) y validación cruzada mediante técnicas de K-Fold.

Estudiantes: Selena Castillo, Joaquín Moscol, Jefferson Sarango, Irvin Armijos, Matías Romero

Link al Google Colab:

<https://colab.research.google.com/drive/18OU6rIIJIYzOg2n-RE8wpfmBf6-m1LNM?usp=sharing>

Preguntas de Control

1. ¿Cuál es la naturaleza de un clasificador cuyo AUC es 0.5 y por qué su comportamiento es ontológicamente indistinguible del azar?

Un AUC de 0.5 significa que la probabilidad de que el modelo asigne un puntaje mayor a un caso positivo que a uno negativo, elegidos al azar, es igual a 0.5 — exactamente lo que se esperaría lanzando una moneda. El modelo no aporta ninguna información discriminante entre clases: su curva ROC coincide con la diagonal de referencia. Por eso es indistinguible del azar: cualquier "acierto" que produzca es estadísticamente equivalente al de adivinar.

2. ¿Es posible afirmar que un modelo es "bueno" basándonos exclusivamente en la exactitud (Accuracy), ignorando la calidad de su juicio sobre las clases minoritarias?

No. En este dataset, la clase "sin acceso a alcantarillado" es minoritaria (~25%). Un modelo trivial que siempre prediga "tiene acceso" alcanzaría una Accuracy cercana al 75% sin haber aprendido nada útil sobre la clase minoritaria. El reporte de clasificación (precisión y recall por clase) y el AUC evitan este engaño, porque evalúan el desempeño en ambas clases y en todos los umbrales.

3. Si un modelo fluctúa drásticamente su rendimiento al cambiar los subconjuntos de datos (folds), ¿podemos decir que posee un "conocimiento" robusto o simplemente ha memorizado patrones accidentales?

Una fluctuación grande entre folds (como la observada, con AUC entre ~0.65 y ~0.94) indica que el modelo es sensible a qué observaciones caen en cada partición, lo cual sugiere que parte de su desempeño depende de particularidades de la muestra (por ejemplo, la distribución específica de provincias en cada fold) y no únicamente de una relación causal estable. No se puede hablar de "conocimiento robusto" hasta que el rendimiento se mantenga consistente entre particiones.

4. Al someter al modelo a múltiples realidades mediante la Validación Cruzada, ¿cómo nos acercamos más a la esencia de su capacidad predictiva en comparación con una prueba única?

Cada fold constituye una "realidad" distinta de partición train/test. Promediar el rendimiento sobre varias particiones reduce la dependencia de una única división afortunada o desafortunada, y la desviación estándar entre folds cuantifica la incertidumbre de la estimación. Así, la Validación Cruzada se acerca más al verdadero poder de generalización del modelo que una sola métrica de una sola partición.

5. ¿Por qué el rigor estocástico y el escepticismo matemático constituyen una virtud necesaria para el ingeniero al momento de comunicar la verdad de sus modelos a la sociedad?

Porque las métricas de un solo experimento pueden ser optimistas o pesimistas por azar, y comunicar solo el mejor resultado (sin su variabilidad) puede inducir decisiones erróneas en contextos con impacto social real, como la planificación de infraestructura pública. El rigor estocástico (reportar medias, desviaciones e intervalos) es una forma de honestidad técnica: reconoce los límites del modelo en vez de sobrevenderlo.

Conclusiones

- Se generó y visualizó correctamente la Curva ROC del modelo de Regresión Logística, obteniendo un AUC de prueba de 0.947, lo que indica una buena capacidad discriminante entre viviendas con y sin acceso a la red pública de alcantarillado.
- El modelo regional (ENEMDU, vivienda-hogar, 2026-02) fue consolidado usando variables estructurales y de ubicación (área, provincia, tipo de vivienda, tenencia, procedencia de agua, alumbrado, número de cuartos).
- La Validación Cruzada K-Fold (K=5) mostró un AUC promedio de 0.815 con una desviación estándar de 0.099, revelando que la estimación de una sola partición (Tarea 1) era ligeramente optimista y que existe variabilidad relevante entre subconjuntos de datos.
- Se construyeron dos visualizaciones de alto impacto (por área y por provincia) que comunican de forma clara la disparidad regional en el acceso a alcantarillado, insumo clave para la exposición de la Casa Abierta.
- El área (urbano/rural) y la provincia resultaron ser, junto al tipo de vivienda y el tipo de alumbrado, los predictores con mayor peso en el modelo, confirmando que el acceso a saneamiento en Ecuador está fuertemente asociado a la ubicación geográfica de la vivienda.

Bibliografía

- [1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. Pearson Educación, 2012.
- [2] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 3ra ed. O'Reilly Media, 2022.
- [3] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011. [Online]. Disponible: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.roc_curve.html. [Accedido: 23-Jul-2026].
- [4] Instituto Nacional de Estadística y Censos (INEC), "Encuesta Nacional de Empleo, Desempleo y Subempleo (ENEMDU) — Módulo de Vivienda y Hogar," *Ecuador en Cifras*, 2026. [Online]. Disponible: <https://www.ecuadorencifras.gob.ec/>. [Accedido: 23-Jul-2026].